

Hackathon 2026

¿Puede un modelo pequeño responder derecho colombiano?

Los modelos de mayor capacidad del mercado fallan al responder derecho colombiano: cerca de la mitad de las normas que citan son erróneas o inexistentes. El reto es construir un sistema con un modelo abierto y pequeño, y un corpus jurídico propio, que los supere.

Universidad de los Andes
Departamento de Ingeniería de Sistemas y Computación
AI Week 2026

ORGANIZAN



VIGILADA MINEDUCACIÓN

PATROCINA

SoftServe



Créditos y agradecimientos

Idea original y diseño de la Hackathon

Rubén Manrique

rf.manrique@uniandes.edu.co

Departamento de Ingeniería de Sistemas y Computación
Universidad de los Andes



Agradecimiento a Software Colombia

La Hackathon 2026 se realiza gracias al patrocinio de **Software Colombia**. Su respaldo hizo posible la convocatoria y la premiación de los tres mejores equipos. Ese acompañamiento permite que un ejercicio académico sobre la fiabilidad de los sistemas de inteligencia artificial en el ámbito jurídico colombiano se desarrolle con estándares profesionales y con proyección más allá del aula. La identidad visual de Software Colombia orienta además uno de los entregables del evento.

Agradecimiento a la Universidad de los Andes

La Universidad de los Andes, a través del Departamento de Ingeniería de Sistemas y Computación, asumió la logística del evento y ofreció de manera generosa los espacios en los que se desarrolla la jornada presencial, incluida la sala Turing para los equipos que requieran capacidad de cómputo adicional. Esa disposición de recursos y de personal es la que permite que la Hackathon se realice en el marco de la AI Week 2026.

Organización

El evento es organizado conjuntamente por la **Universidad de los Andes** y **SoftServe**, en el marco de la AI Week 2026.

Contenido

1. Planteamiento del reto	3
2. Estructura del evento	3
3. Restricciones de cómputo	4
3.1. Requisitos obligatorios	4
3.2. Prohibiciones	4
3.3. Técnicas admitidas	4
4. Material entregado en la sesión inaugural	4
4.1. Preguntas de muestra	4
4.2. Composición del banco	5
4.3. Fuentes normativas	5
4.4. Herramientas	5
5. Pasos obligatorios	6
Paso 1. Ingesta y normalización	6
Paso 2. Indexación vectorial	6
Paso 3. Generación con el modelo de lenguaje	6
Paso 4. Citas y abstención	6
Paso 5. Enriquecimiento documentado del corpus	7
6. Calificación	7
6.1. Componente automático, sobre el conjunto de evaluación ciego — 80 puntos	7
6.2. Componente de interfaz, corpus e ingeniería — 20 puntos	8
7. Verificación en vivo	9
8. Integridad académica	9
9. Entregables	9
9.1. Primer momento — viernes, 17:00	9
9.2. Segundo momento — sábado, 15:00	9
9.3. Publicación del corpus y del índice vectorial	10
10. Condiciones de participación	10
A. Formato de entrega	10
B. Conceptos técnicos	11
B.1. Modelo de lenguaje y <i>decoder</i>	11
B.2. <i>Encoder</i> y representaciones vectoriales	12
B.3. Índices vectoriales y FAISS	12
B.4. Generación aumentada por recuperación (RAG)	13
B.5. Enfoque agéntico sobre RAG	13
B.6. Glosario	14

1. Planteamiento del reto

En 2026 se publicó el primer *benchmark* de fiabilidad de modelos de lenguaje sobre derecho colombiano: **1.042 preguntas** redactadas y verificadas por juristas, correspondientes a diez áreas del ordenamiento jurídico, cada una con su respuesta esperada y su fundamento normativo. El estudio evaluó quince modelos, incluidos los de mayor capacidad disponibles en el mercado.

Los resultados evidencian limitaciones sustantivas:

Resultado	Valor
Mejor exactitud en preguntas cerradas	0,905 (Gemini 3.1 Pro)
Mejor corrección en respuestas de texto libre (RAGAS)	0,451 (GPT-5.4)
Normas citadas que resultan erróneas o inexistentes	Aproximadamente la mitad
Correlación entre pertinencia aparente y corrección	$\rho = -0,46$ (negativa)

El último resultado es particularmente relevante. Los modelos cuyas respuestas presentan mayor apariencia de rigor no son los que responden con mayor corrección, porque producen prosa jurídica formalmente adecuada sustentada en disposiciones inexistentes. Un profesional del derecho que no verifique las fuentes no dispone de indicios para detectarlo.

Todos los modelos evaluados respondieron sin acceso a fuentes externas.

Objetivo del reto. Construir un sistema que, mediante un **modelo abierto de tamaño reducido** (≤ 8.000 millones de parámetros) y un **corpus jurídico propio**, supere el desempeño de dichos modelos. La ventaja proviene de la disponibilidad de las fuentes normativas y de la calidad de su recuperación, más que del número de parámetros.

La hipótesis de trabajo es que el corpus determina el desempeño en mayor medida que el modelo. En la construcción del corpus se concentra el valor del ejercicio.

Esta edición de la Hackathon se realiza en el marco de la AI Week 2026 de la Universidad de los Andes y cuenta con el patrocinio de **Software Colombia**, cuya identidad visual orienta además uno de los entregables del sábado (sección 6).

2. Estructura del evento

Momento	Actividad
Lunes, sesión inaugural	Entrega de la totalidad del material: enunciado, 50 preguntas de muestra con respuesta, listado de fuentes normativas, evaluador oficial y la llave de acceso al juez de texto libre.
Martes a viernes	Trabajo remoto. La actividad central es la construcción y el enriquecimiento del corpus. Autoevaluación mediante <code>evaluate.py</code> sobre las 50 preguntas de muestra, con los cuatro componentes automáticos.
Viernes, 13:00 – 17:00	Charlas de la AI Week. Asistencia obligatoria.
Viernes, 17:00	Punto de control: reporte de avance de una página, con el puntaje obtenido sobre las preguntas de muestra.
Sábado, 9:00	Entrega presencial, en la Universidad, de las 992 preguntas restantes, sin respuestas.
Sábado, 9:00 – 15:00	Ejecución ciega y desarrollo de la interfaz gráfica, en el equipo de cómputo del grupo y en el recinto del evento.

Sábado, 15:00	Cierre de entregas.
Sábado, 15:00 – 17:00	Verificación en vivo (sección 7).
Sábado, 18:00 – 19:00	Resultados y premiación de los tres mejores equipos.

No se contemplan presentaciones ni sustentación oral. La exposición del trabajo se realiza mediante el video de cinco minutos.

3. Restricciones de cómputo

3.1 Requisitos obligatorios

- **Decoder abierto de 8.000 millones de parámetros o menos.** Opciones sugeridas: Qwen/Qwen3-8B, meta-llama/Llama-3.1-8B-Instruct, BSC-LT/salamandra-7b-instruct (entrenado en español). Se admite cuantización de 4 u 8 bits; la restricción aplica al número de parámetros, no a la precisión numérica.
- **Encoder abierto** para la generación de representaciones vectoriales. Opciones sugeridas: intfloat/multilingual-e5-large, BAAI/bge-m3, jinaai/jina-embeddings-v3.
- **Temperatura 0** en la ejecución final. Su sistema debe ser determinista.

3.2 Prohibiciones

Las siguientes conductas constituyen causal de descalificación:

- Uso de modelos cerrados (OpenAI, Anthropic, Google, Cohere u otros) en cualquier componente del sistema: ni para la generación de respuestas, ni para la reformulación de consultas, ni para el reordenamiento de resultados, ni para la producción de datos sintéticos de apoyo.
- Edición manual de las respuestas con posterioridad a la ejecución.
- Indexación del banco de preguntas o de cualquier material que contenga respuestas esperadas (sección 8).

3.3 Técnicas admitidas

Se admiten y se valoran positivamente la recuperación híbrida (BM25 combinado con recuperación densa), el reordenamiento mediante un *reranker* abierto, la expansión de consultas, la construcción de grafos normativos y cualquier otra técnica compatible con las restricciones anteriores.

Los equipos que no dispongan de unidad de procesamiento gráfico pueden usar la sala Turing y la capa gratuita de Google Colab durante la semana del evento.

4. Material entregado en la sesión inaugural

4.1 Preguntas de muestra

`data/sample_50.jsonl` contiene 50 ítems —15 cerrados, 30 semiabiertos y 5 abiertos— con su `respuesta_esperada` y `su_legal_basis`. La muestra cubre las diez áreas del ordenamiento y los tres niveles de complejidad. Constituye el conjunto de desarrollo del reto.

Estos 50 ítems no forman parte de la evaluación del sábado, que se realiza sobre los 992 restantes.

4.2 Composición del banco

El temario se publica de manera íntegra. La siguiente tabla presenta las diez áreas y su peso exacto en el banco completo de 1.042 ítems:

Área	Cerradas	Semiab.	Abiertas	Total
Derecho constitucional	39	86	9	134
Derecho administrativo	53	63	8	124
Derecho penal	26	93	4	123
Derecho procesal	37	71	3	111
Derecho comercial y sociedades	26	70	8	104
Derecho civil	27	70	5	102
Derecho de familia	32	59	2	93
Derecho tributario	22	66	4	92
Derecho laboral	23	58	6	87
Derecho de los mercados (competencia, consumidor, datos personales, propiedad intelectual)	20	46	6	72

Las preguntas semiabiertas persiguen un catálogo fijo de sub-tareas jurídicas en cada nivel de complejidad (258 ítems de complejidad baja, 236 media y 188 alta):

- **Complejidad baja.** Existencia normativa; autoridad competente; juez que decide; jerarquía normativa; definición básica; clasificación jurídica; elementos esenciales.
- **Complejidad media.** Sentido del fallo; reproducción literal de una norma; precedente jurisprudencial; vigencia temporal; distinción conceptual; requisitos legales; excepciones legales; imparcialidad del orden judicial.
- **Complejidad alta.** Conflicto normativo; supuestos fácticos; postura procesal; problema jurídico; fundamento jurídico central; ponderación de principios y derechos; interpretación sistemática.

Las preguntas abiertas son casuísticas: plantean un problema jurídico y esperan un análisis completo que comprenda marco normativo, aplicación al caso y conclusión.

Una precisión sobre el alcance del banco. El banco no cubre derecho ambiental ni derecho internacional, por lo que no se requiere trabajo sobre esas áreas.

4.3 Fuentes normativas

`data/seed_targets.json` contiene un listado de cuerpos normativos que pueden resultar útiles para la construcción del sistema de recuperación, con la indicación de dónde se publica cada uno. **No se entregan los documentos.** Cada equipo debe descargarlos y procesarlos.

El listado es deliberadamente **no exhaustivo**: no cubre la totalidad de las normas que el banco requiere, y los equipos pueden y deben incorporar muchos más documentos. Cerrar esa brecha constituye el trabajo de la semana.

4.4 Herramientas

Archivo	Función
<code>scripts/evaluate.py</code>	Evaluador oficial, idéntico al que ejecuta el jurado.
<code>scripts/requirements-evaluador.txt</code>	Dependencias del juez de texto libre.
<code>schema/submission.schema.json</code>	Contrato de salida de la entrega.

Sobre el juez de texto libre. El componente de corrección en texto libre (sección 6.1) se calcula con un modelo juez alojado en OpenRouter. La llave de acceso se entrega en la sesión inaugural y se declara en la variable de entorno `OPENROUTER_API_KEY`. Con ella, cada equipo puede autoevaluar durante la semana los cuatro componentes automáticos sobre las 50 preguntas de muestra:

```
pip install -r scripts/requirements-evaluador.txt
python scripts/evaluate.py --submission entrega.jsonl --split sample --ragas
```

Sin la bandera `--ragas` el evaluador corre igual y reporta los 50 puntos que no dependen del juez. El modelo de representaciones vectoriales que interviene en la métrica se ejecuta de manera local y no consume la llave.

No se entrega una implementación de referencia. La arquitectura del sistema, la segmentación del corpus, la estrategia de recuperación y el diseño de los prompts son decisiones de cada equipo. El anexo B presenta los conceptos técnicos necesarios para abordarlas.

5. Pasos obligatorios

Paso 1. Ingesta y normalización

Descargar y buscar los documentos que alimentarán la base de datos del sistema, y transformar el documento crudo en texto limpio con metadatos: tipo de norma, número, año, artículo, órgano emisor y vigencia.

Requisito mínimo: cada fragmento indexado debe permitir identificar la norma y el artículo de los que procede. Sin esta trazabilidad, el paso 4 no es realizable.

Paso 2. Indexación vectorial

Requisitos mínimos: uso de un encoder abierto; e índice reconstruible mediante un script.

Paso 3. Generación con el modelo de lenguaje

Requisito mínimo: producción del objeto JSON correspondiente a cada formato, con las claves que se indican a continuación. El diseño del prompt que conduce a ese resultado corresponde a cada equipo.

- **Cerradas:** `respuesta_correcta` (letra), `justificacion`, `descarte_opciones`.
- **Semiabiertas:** `respuesta` (de 3 a 5 oraciones, máximo 150 palabras), `palabras_clave`, `referencia_legal`.
- **Abiertas:** `marco_normativo`, `analisis` (de 5 a 8 oraciones), `jurisprudencia`, `conclusion`.

Las claves del objeto JSON son obligatorias y no admiten modificación, dado que sobre ellas opera el evaluador. Su contenido, su extensión y el prompt que las produce quedan a discreción del equipo, dentro de los límites de extensión indicados.

Paso 4. Citas y abstención

Requisitos mínimos:

- Toda norma citada debe proceder de un pasaje efectivamente recuperado. Si el modelo cita el artículo 42 del Código General del Proceso, dicho artículo debe figurar entre los `pasajes_recuperados` de esa respuesta.
- El sistema debe disponer de un mecanismo de abstención, que registre `abstencion: true` cuando el corpus no proporcione fundamento suficiente.

El requisito de respaldo tiene consecuencia directa en la calificación. Una norma correctamente referenciada pero ausente de la evidencia recuperada obtiene la mitad del valor de una citación respaldada, y una citación que no corresponde al fundamento de referencia ni figura en la evidencia se penaliza (sección 6.1). Un sistema que responda de memoria, sin recuperar las fuentes que cita, obtiene por tanto la mitad del puntaje de uno equivalente que las fundamente.

Este paso responde directamente al hallazgo central del estudio de referencia y representa 30 de los 100 puntos de la calificación.

Paso 5. Enriquecimiento documentado del corpus

Constituye la actividad central de la semana. Los equipos deben identificar y obtener las fuentes que el sistema requiere, con base en la composición del banco expuesta en la sección 4.2 y en los campos `legal_basis` de las preguntas de muestra.

Fuentes admitidas. Cualquier fuente pública y de libre distribución: SUIN-Juriscol, Secretaría del Senado, relatorías de la Corte Constitucional, la Corte Suprema de Justicia y el Consejo de Estado, DIAN, SIC y Diario Oficial.

Entregable: `CORPUS.md`. La bitácora del corpus debe contener cuatro secciones:

1. **Inventario.** Por cada documento incorporado: título, fuente, URL, fecha de consulta, número de artículos o páginas, y áreas del banco a las que responde.
2. **Criterio.** Justificación de la selección documental frente a las áreas y sub-tareas del banco.
3. **Método.** Procedimiento de ingesta y limpieza: reconocimiento óptico de caracteres, segmentación y extracción de metadatos.

Se requiere adicionalmente un archivo `corpus_manifest.json` en la raíz del corpus, con un registro por documento que incluya los campos `doc_id`, `título`, `fuentes`, `url`, `fecha_consulta` y `areas`.

6. Calificación

La calificación total es de 100 puntos.

6.1 Componente automático, sobre el conjunto de evaluación ciego — 80 puntos

Componente	Puntos	Procedimiento
Exactitud en preguntas cerradas	20	Aciertos sobre 289 ítems. Valor de referencia a superar: 0,905.
Corrección en texto libre	30	RAGAS <i>answer correctness</i> sobre 250 ítems estratificados, con un único juez (<code>z-ai/glm-5.3-flash</code>). Valor de referencia a superar: 0,451.
Calidad de citación	20	<i>Recall</i> ponderado de las normas del fundamento de referencia, menos el doble de la tasa de citas sin respaldo en la evidencia recuperada.
Abstención calibrada	10	Una respuesta correcta computa 1; la abstención, 0,5; una respuesta errónea, 0.

Cada norma citada se clasifica según dos criterios independientes —si corresponde al fundamento de referencia y si figura en los pasajes recuperados de esa misma respuesta:

Clasificación	Valor
---------------	-------

Corresponde al fundamento de referencia y está respaldada por la evidencia recuperada	1,0
Corresponde al fundamento de referencia, pero se afirma sin respaldo en la evidencia	0,5
No corresponde al fundamento de referencia, pero está respaldada por la evidencia	0 (sin penalización)
No corresponde al fundamento de referencia ni está respaldada por la evidencia	Penalización equivalente al doble de un acierto

La citación correcta pero sin respaldo recibe la mitad del valor porque el sistema no puede acreditar su procedencia. Ese es el patrón que el estudio de referencia identifica como el de mayor riesgo, y su detección constituye el objeto central del reto. La citación pertinente aunque no idéntica a la referencia no se penaliza, dado que un mismo problema jurídico admite más de una vía de fundamentación.

Para el cómputo del respaldo se consideran los primeros diez pasajes de cada respuesta, de modo que este no pueda satisfacerse adjuntando el corpus completo en cada ítem.

Sobre la abstención. Una respuesta debidamente fundamentada tiene mayor valor que la abstención, y la abstención tiene mayor valor que una citación sin respaldo en la evidencia. La abstención sistemática produce 5 puntos y cero en los tres componentes restantes, por lo que no constituye una estrategia competitiva.

6.2 Componente de interfaz, corpus e ingeniería – 20 puntos

Componente	Puntos	Criterio
Interfaz gráfica	10	Consulta de extremo a extremo desde la interfaz (4); visualización de los pasajes recuperados y de las normas citadas en cada respuesta (3); aplicación de la identidad visual de Software Colombia (3).
Bitácora y corpus publicado	5	Inventario completo y trazable (2); justificación frente a la composición del banco (1,5); corpus reconstruible a partir de las URL declaradas (1,5).
Video de máximo 5 minutos	3	Único componente evaluado por jurados humanos.
Reproducibilidad	2	Verificación automática: el repositorio se ejecuta desde cero mediante un único comando, en contenedor limpio, sobre las preguntas de muestra.

Sobre la interfaz gráfica. Se desarrolla durante la semana y se perfecciona el sábado, en paralelo con la ejecución ciega. Debe permitir formular una pregunta jurídica y obtener la respuesta del sistema junto con la evidencia que la sustenta. Su diseño debe inspirarse en la identidad visual de **Software Colombia**, patrocinador del evento. No se exige despliegue público; es suficiente con que funcione en el equipo del grupo durante la verificación en vivo.

El video debe exponer la arquitectura del sistema, las decisiones relativas al corpus y su justificación, el funcionamiento del sistema de extremo a extremo con sus pasajes recuperados, y las limitaciones identificadas por el propio equipo. La identificación precisa de las limitaciones del sistema se valora por encima de su presentación como solución infalible.

7. Verificación en vivo

La verificación se realiza el sábado entre las 15:00 y las 17:00, con una duración aproximada de diez minutos por equipo.

El jurado selecciona de manera aleatoria dos o tres preguntas ya entregadas y solicita su regeneración con el sistema del equipo en ese momento. El resultado se contrasta con lo entregado.

Criterio de aprobación. Deben coincidir las normas citadas y los pasajes recuperados. Se admite variación en la redacción, si bien con temperatura 0 la coincidencia debe ser prácticamente literal.

El procedimiento no constituye una defensa ni una sustentación, y no requiere explicación por parte del equipo. Se trata de una verificación binaria de correspondencia entre el sistema entregado y las respuestas presentadas. La divergencia sustantiva o la imposibilidad de reproducir el resultado constituyen causal de descalificación.

El índice debe congelarse en el momento de la entrega y no puede modificarse con posterioridad.

8. Integridad académica

El banco completo de preguntas con sus respuestas se publica con posterioridad a la premiación.

Causales de descalificación.

1. Uso de un modelo cerrado en cualquier componente del sistema.
2. Edición manual de respuestas.
3. Presencia de ítems del conjunto de evaluación o de material con respuestas dentro del índice.
4. Resultado negativo en la verificación en vivo.

9. Entregables

Los entregables se reparten en dos momentos, con canales distintos. La carpeta `entregables/` del material del reto contiene las plantillas e instrucciones de cada uno.

9.1 Primer momento — viernes, 17:00

El reporte de avance se remite por correo electrónico a rf.manrique@uniandes.edu.co, con el asunto [Hackathon 2026] Avance – <nombre del equipo>.

N.º	Entregable	Formato
1	Reporte de avance de una página, con el puntaje obtenido sobre las 50 preguntas de muestra, el estado del corpus y los riesgos identificados	PDF adjunto al correo

9.2 Segundo momento — sábado, 15:00

La entrega se consolida en el repositorio del equipo. El enlace del repositorio se registra en la plataforma que se indica en la sesión inaugural.

N.º	Entregable	Ubicación
2	Repositorio (GitHub o GitLab) con archivo README que documente dependencias, arquitectura y comando único de reproducción	Repositorio
3	<code>submissions.jsonl</code> con las 992 respuestas conforme al esquema oficial	Repositorio
4	<code>CORPUS.md</code> y <code>corpus_manifest.json</code>	Repositorio

5	Corpus enriquecido e índice vectorial, bajo licencia abierta	Servicio en la nube, con el enlace declarado en el repositorio
6	Informe técnico de máximo 3 páginas: arquitectura, selección de encoder y decoder, resultados sobre las preguntas de muestra y limitaciones	Repositorio
7	Video de duración máxima de 5 minutos	Repositorio o enlace en la nube
8	Interfaz gráfica funcional, inspirada en la identidad visual de Software Colombia	Repositorio

9.3 Publicación del corpus y del índice vectorial

El corpus enriquecido y el índice vectorial construido sobre él no se versionan en el repositorio, dado su tamaño. Cada equipo los deposita en un servicio de almacenamiento en la nube (Google Drive, OneDrive, Dropbox, Zenodo u otro equivalente) y declara el enlace en el archivo README del repositorio, dentro de una sección titulada *Corpus e índice*.

El enlace debe cumplir tres condiciones:

1. Permitir la descarga sin solicitud de permiso adicional, con acceso de lectura para cualquier persona que disponga del vínculo.
2. Permanecer activo durante los treinta días siguientes al evento, para efectos de reutilización.
3. Apuntar a un archivo comprimido que contenga el corpus procesado, el índice vectorial serializado y un archivo LICENSE con la licencia abierta escogida por el equipo.

Un enlace inaccesible en el momento de la calificación equivale a la ausencia del entregable correspondiente.

10. Condiciones de participación

- Asistencia presencial obligatoria a la sesión inaugural del lunes (recibiran un kit), a las charlas de la AI Week del viernes 02 de Octubre 13:00 a 17:00, y a la jornada completa del sábado 03 de Octubre (incluida la premiación).
- Asistencia presencial en la Universidad a la charla del Martes 29: Software Development Lifecycle with AI.
- Todos los participantes de la hackathon ha sido asignados al menos a uno de los workshops certificados de la AI Week. Su asistencia y certificación es obligatoria.
- **Premiación a los tres mejores equipos.**

Preguntas. Cualquier duda sobre el enunciado, el material o la logística del evento se dirige a rf.manrique@uniandes.edu.co.

A. Formato de entrega

La entrega consiste en un archivo con una línea JSON por ítem. El esquema validable se encuentra en `schema/submission.schema.json`.

Pregunta cerrada.

```
{
  "id": 1, "formato": "multiple_choice", "abstencion": false,
  "respuesta_correcta": "A",
  "justificacion": "El articulo 899 delCodigo de Comercio establece que...",
  "descarte_opciones": {"B": "confunde inexistencia con nulidad", "C": "...", "D": "..."},
  "pasajes_recuperados": [
    {
      "doc_id": "codigo_comercio.txt", "inicio": 184320, "fin": 184690,
      "texto": "ARTICULO 899. Sera nulo absolutamente el negocio juridico...",
      "score": 0.87}]]}
```

Pregunta semiabierta.

```
{
  "id": 512, "formato": "semi_open", "abstencion": false,
  "respuesta": "El termino es de diez dias habiles, contados a partir de la notificacion...",
  "palabras_clave": ["proceso verbal sumario", "contestacion", "diez dias"],
  "referencia_legal": "Articulo 391 delCodigo General del Proceso",
  "pasajes_recuperados": [
    {
      "doc_id": "ley_1564_2012.txt", "texto": "ARTICULO 391...", "score": 0.91}]]}
```

Pregunta abierta con abstención.

```
{
  "id": 987, "formato": "open_ended", "abstencion": true,
  "marco_normativo": "", "analisis": "", "jurisprudencia": "", "conclusion": "",
  "pasajes_recuperados": []}
```

B. Conceptos técnicos

Este anexo expone los componentes técnicos que intervienen en el reto. No prescribe una arquitectura. Describe las piezas disponibles y la función que cumple cada una, de modo que las decisiones de diseño puedan tomarse con fundamento.

B.1 Modelo de lenguaje y *decoder*

Un **modelo de lenguaje de gran escala** (LLM, *large language model*) es un modelo estadístico entrenado para predecir el siguiente fragmento de texto dado el texto precedente. El texto se representa como una secuencia de **tokens** —unidades subléxicas, del orden de tres a cuatro caracteres en español— y el modelo asigna a cada token posible una probabilidad condicionada a la secuencia anterior. La generación de una respuesta consiste en repetir esa predicción token por token.

El término ***decoder*** designa la arquitectura empleada por estos modelos: una red de tipo *Transformer* que procesa la secuencia en una sola dirección, de izquierda a derecha, y produce texto nuevo. Se distingue del *encoder* descrito en B.2, que representa el texto en lugar de generarlo.

Cuatro parámetros resultan relevantes para el reto:

Parámetro	Significado
Número de parámetros	Cantidad de pesos ajustables del modelo. La restricción del reto es de 8.000 millones (8B). Aproxima la capacidad del modelo, no su calidad en una tarea concreta.
Ventana de contexto	Número máximo de tokens que el modelo procesa en una llamada. Limita cuánta evidencia recuperada cabe en el prompt.
Temperatura	Controla la aleatoriedad del muestreo. En 0 el modelo elige siempre el token más probable, y la salida es reproducible. El reglamento la fija en 0.
Cuantización	Reducción de la precisión numérica de los pesos (de 16 a 8 o 4 bits). Disminuye el consumo de memoria con una pérdida de calidad limitada, y permite ejecutar un modelo de 8B en una GPU de 12 GB.

Origen de las citas falsas. El modelo no distingue internamente entre lo que memorizó durante el entrenamiento y lo que está completando por verosimilitud estadística. Una referencia normativa

—«artículo 42 de la Ley 1564 de 2012»— es, desde el punto de vista del modelo, una secuencia de tokens con alta probabilidad en ese contexto. Nada en su objetivo de entrenamiento penaliza que la disposición no exista. De ahí que la fluidez de la respuesta no constituya evidencia de su corrección, y que la correlación reportada en la sección 1 sea negativa.

B.2 Encoder y representaciones vectoriales

Un **encoder** transforma un fragmento de texto en un vector de números reales de dimensión fija —típicamente entre 384 y 1.024 componentes— denominado **embedding** o representación densa. El modelo se entrena de modo que dos textos de significado próximo reciban vectores próximos en ese espacio, y textos de significado distante reciban vectores distantes.

La proximidad se mide habitualmente mediante la **similitud coseno**, es decir el coseno del ángulo entre los dos vectores. Si los vectores se normalizan a longitud unitaria, la similitud coseno coincide con su producto interno, lo que permite calcularla como una simple multiplicación.

Esto habilita la **búsqueda semántica**: en lugar de localizar documentos que contengan literalmente las palabras de la consulta, se localizan los documentos cuya representación es más próxima a la representación de la consulta. Una pregunta sobre «terminación unilateral del contrato de trabajo» puede así recuperar un artículo que emplea la expresión «despido sin justa causa».

Dos precisiones de orden práctico:

- El *encoder* no genera texto y no responde preguntas. Su única función es representar. Es un modelo independiente del *decoder*, y en este reto ambos deben ser abiertos.
- Varios *encoders* multilingües requieren prefijos específicos en la entrada. Los de la familia E5, por ejemplo, esperan *query*: antes de una consulta y *passage*: antes de un fragmento del corpus. Omitir esos prefijos degrada la recuperación de forma apreciable y silenciosa.

Segmentación del corpus. El *encoder* representa fragmentos, no documentos completos. Un código de mil artículos no puede reducirse a un solo vector sin perder toda especificidad. La decisión de **cómo fragmentar** el corpus (*chunking*) determina qué se puede recuperar. El enunciado exige segmentar a nivel de artículo porque el artículo es la unidad de sentido del texto normativo; un fragmento que corta un artículo por la mitad puede no contener ya la disposición que responde a la pregunta.

B.3 Índices vectoriales y FAISS

Una vez representado el corpus como un conjunto de N vectores, responder una consulta exige identificar los k vectores más próximos al de la consulta. El procedimiento exacto consiste en calcular la similitud contra los N vectores y ordenar el resultado; su costo crece linealmente con N .

FAISS (*Facebook AI Similarity Search*) es una biblioteca de código abierto que implementa estructuras de datos para esta operación. Ofrece dos familias de índices:

Familia	Comportamiento
Exacta (IndexFlatIP, IndexFlatL2)	Compara contra todos los vectores. Devuelve siempre los vecinos verdaderos. Adecuada hasta el orden de centenares de miles de fragmentos.
Aproximada (IVF, HNSW, PQ)	Reduce el espacio de búsqueda mediante agrupamiento (IVF), grafos de proximidad (HNSW) o compresión de vectores (PQ). Acelera la consulta y reduce la memoria, a costa de omitir ocasionalmente algún vecino verdadero.

Para un corpus normativo de la escala de este reto, un índice exacto es suficiente y evita la pérdida de recuperación asociada a los métodos aproximados. FAISS es una opción entre varias —también

son válidas Chroma, Qdrant, LanceDB, o incluso una matriz de NumPy con un producto de matrices—, y la elección del índice no es el factor que determina el desempeño.

Recuperación léxica y recuperación híbrida. Los *embeddings* representan significado, y por ello son deficientes con identificadores exactos. Los vectores de «artículo 42» y «artículo 24» son casi indistinguibles, pese a designar disposiciones distintas. **BM25** es una función de puntuación léxica clásica, basada en la frecuencia de los términos de la consulta en cada documento, que resuelve bien precisamente ese caso. La **recuperación híbrida** combina ambas señales —léxica y densa— y suele superar a cada una por separado en dominios jurídicos, donde la referencia numérica es constitutiva.

Reordenamiento. Un **reranker** es un modelo que recibe conjuntamente la consulta y un fragmento candidato, y emite una puntuación de pertinencia. Al procesar ambos textos a la vez es más preciso que la comparación de vectores independientes, y también considerablemente más costoso. El uso habitual consiste en recuperar un conjunto amplio de candidatos con el índice vectorial y reordenar únicamente esos candidatos con el *reranker*.

B.4 Generación aumentada por recuperación (RAG)

RAG (*retrieval-augmented generation*) designa la combinación de un sistema de recuperación con un modelo generativo. El procedimiento consta de cuatro etapas:

- 1. **Indexación**, previa a toda consulta: el corpus se segmenta, se representa con el *encoder* y se almacena en el índice vectorial.
- 2. **Recuperación**: la consulta se representa con el mismo *encoder* y se obtienen los *k* fragmentos más próximos.
- 3. **Aumento**: los fragmentos recuperados se insertan en el prompt del *decoder*, junto con la pregunta y las instrucciones de formato.
- 4. **Generación**: el *decoder* produce la respuesta a partir de ese contexto.

La relevancia de este enfoque para el problema planteado es directa. El modelo ya no debe recordar el texto del artículo 42, porque lo tiene delante. Y puesto que la evidencia empleada es explícita, la citación resulta verificable —lo que hace posible el componente de respaldo descrito en la sección 6.1.

RAG desplaza el problema en lugar de eliminarlo. Si la recuperación devuelve fragmentos que no contienen la disposición aplicable, el modelo puede completar la laguna con una referencia inventada, exactamente igual que sin recuperación. El desempeño del sistema queda por tanto acotado por la calidad del corpus y de la recuperación, más que por la capacidad del *decoder*. De ahí que la construcción del corpus sea la actividad central de la semana.

B.5 Enfoque agéntico sobre RAG

El esquema de B.4 realiza una sola pasada: una consulta, una recuperación, una generación. Un **enfoque agéntico** dota al sistema de la capacidad de decidir sobre su propio proceso de resolución, ejecutando varios ciclos antes de emitir una respuesta.

RAG lineal	RAG agéntico
La pregunta se usa como consulta tal cual.	La pregunta se descompone en sub-consultas, o se reformula con terminología jurídica.
Una única recuperación.	Recuperación iterativa: lo recuperado en un ciclo orienta la consulta del siguiente.
Se genera con lo que haya llegado.	El sistema evalúa si la evidencia es suficiente y, si no lo es, vuelve a recuperar.

Sin verificación de la salida.	El sistema comprueba que cada norma citada figura en la evidencia recuperada, y corrige o suprime la citación en caso contrario.
No contempla la abstención.	La abstención es una decisión explícita, adoptada cuando la evidencia resulta insuficiente tras varios intentos.

Aplicado a este reto, un ciclo agéntico plausible sería:

1. Identificar el área del ordenamiento y la sub-tarea que la pregunta plantea.
2. Formular una consulta de recuperación y ejecutarla.
3. Determinar si los fragmentos obtenidos contienen la disposición aplicable.
4. Si no la contienen, reformular la consulta —por ejemplo, con el nombre del cuerpo normativo probable— y repetir.
5. Redactar la respuesta exclusivamente con la evidencia reunida.
6. Verificar que toda norma citada aparece en esa evidencia; en caso contrario, suprimir la citación o declarar la abstención.

Los pasos 3 y 6 corresponden a los dos componentes de mayor peso en la calificación (respaldo de las citas y calidad de citación) y son realizables sin capacidades adicionales del modelo: basta comparar las referencias citadas con las presentes en los fragmentos, lo que constituye una operación de procesamiento de texto.

Restricción de tiempo. Cada ciclo adicional implica una llamada adicional al modelo. La ejecución del sábado comprende 992 preguntas en aproximadamente seis horas, lo que equivale a un promedio disponible de unos **22 segundos por pregunta**. Un diseño agéntico de cuatro o cinco pasadas por pregunta puede resultar inviable en ese presupuesto. La arquitectura debe dimensionarse en consecuencia. Conviene medir el tiempo por pregunta desde el inicio de la semana, y reservar la iteración adicional para los casos en que la primera recuperación resulte insuficiente, en lugar de aplicarla de manera uniforme.

B.6 Glosario

Término	Definición breve
Token	Unidad mínima de texto que procesa el modelo, del orden de tres a cuatro caracteres.
Embedding	Vector de dimensión fija que representa el significado de un fragmento de texto.
Encoder	Modelo que produce <i>embeddings</i> . No genera texto.
Decoder	Modelo que genera texto token por token. Es el LLM propiamente dicho.
Chunking	Segmentación del corpus en los fragmentos que serán indexados y recuperados.
Top-k	Número de fragmentos que la recuperación devuelve por consulta.
BM25	Función de puntuación léxica basada en la frecuencia de términos.
Reranker	Modelo que reordena candidatos evaluando conjuntamente consulta y fragmento.
RAG	Generación de la respuesta a partir de fragmentos recuperados de un corpus.
Cuantización	Reducción de la precisión numérica de los pesos para disminuir el uso de memoria.

Temperatura	Parámetro de aleatoriedad del muestreo. En 0, la salida es reproducible.
-------------	--



PATROCINADOR DE LA HACKATHON 2026

Agradecimiento

La Hackathon 2026 se realiza gracias al patrocinio de **Software Colombia**. Su respaldo hizo posible la convocatoria y la premiación de los tres mejores equipos.

Ese acompañamiento permite que un ejercicio académico sobre la fiabilidad de los sistemas de inteligencia artificial en el ámbito jurídico colombiano se desarrolle con estándares profesionales y con proyección más allá del aula.

La Universidad de los Andes y SoftServe, organizadoras del evento, extienden este reconocimiento a Software Colombia y a quienes participaron en la preparación de la Hackathon.

Hackathon 2026 · AI Week
Universidad de los Andes
Departamento de Ingeniería de Sistemas y Computación
rf.manrique@uniandes.edu.co