

RAG de derecho colombiano

Equipo P34K · Informe de preparación del corpus · 2026-09-30

1. Corpus y procedencia

Se preservan los textos preparados y los originales descargados. La ampliación prioriza normas citadas ausentes y fuentes oficiales de las diez áreas. Las etiquetas de área se obtienen de catálogos y heurísticas. No equivalen a cobertura jurídica completa.

Medida	Resultado
Documentos iniciales	13,967
Documentos nuevos únicos	14,150
Inventario final	28,117
Núcleo apto para búsqueda	17,833
Complementarios aptos	10,276
Fallos de integridad en auditoría	0

Los registros conservan URL, procedencia y hashes. Se completan normas HTML divididas en páginas y se rechazan extracciones defectuosas. El OCR conserva el escaneo y su trazabilidad. Sus revisiones parciales se identifican expresamente. La vigencia requiere revisión jurídica. Las notas editoriales de terceros conservan sus restricciones.

2. Auditoría de cobertura

Referencia de la muestra	Resultado
norma_ausente	2
articulo_ausente	0
no_recuperada	42
recuperada	15

Se evalúan 59 referencias explícitas. 11 preguntas no tienen una referencia evaluable con estas reglas y se informan aparte. El diagnóstico usa SQLite FTS5 BM25 con top 20. No mide recuperación vectorial ni corrección de respuestas.

La muestra se usa para desarrollo. Sus respuestas esperadas permanecen fuera del corpus, del índice y del contexto entregado al generador.

3. Pipeline y ejecución

La fase 0 mantiene artículos completos como unidades citables y crea ventanas de búsqueda de 512 tokens con solapamiento de 64. Las sentencias se organizan por párrafos. Cada ventana conserva jerarquía, identificador y offsets sobre el texto canónico.

BGE-M3 vectoriza ventanas con encabezado jurídico. Los vectores normalizados se guardan en FAISS FlatIP. El núcleo y el complemento se construyen y consultan por separado para limitar la RAM. SQLite conserva los textos y permite recuperación híbrida opcional.

La inferencia recupera 50 candidatos, aplica BGE-reranker-v2-m3 y conserva diez pasajes. Las preguntas complejas permiten HyDE. El borrador hipotético solo amplía la búsqueda. Si la evidencia del núcleo es débil, se consulta el complemento.

Qwen 2.5-7B-Instruct se carga en bfloat16 sobre la GPU de 24 GB. Genera sin muestreo con `repetition_penalty=1.1`, dentro del presupuesto de contexto de 5500 tokens. Las cerradas permiten descarte de opciones. Las citas se vinculan con evidencia recuperada. La salida JSON se valida contra el esquema oficial.

4. Reproducibilidad y límites

El corpus, los modelos y la configuración quedan identificados por hashes y revisiones. La ejecución guarda respuestas y trazas por pregunta y permite reanudar con la misma configuración. Un cambio de corpus, encoder o fragmentación requiere reconstruir el índice. Cambiar prompts, reranker, umbral o búsqueda híbrida reutiliza el índice.

En la muestra de 50 preguntas: 50/50 respondidas (0 abstenciones), JSON válido en las 50 salidas, top-3 retrieval promedio 0.898, latencia media ~6.4s/pregunta en RTX 4090. El umbral de reranker de 0,25 necesita calibración y el score del reranker no es una probabilidad de acierto.

5. Entrega

El README documenta audit, index, run, evaluate y serve. El banco final se recibe con `--questions. submissions.jsonl` solo se genera al responder sus 992 preguntas. Corpus e índice se publican fuera del repositorio con manifiesto y LICENSE. El enlace público y las métricas de inferencia se completan antes de entregar.

Evidencia: `reports/ampliacion_corpus.json`, `reports/cobertura.json`, `reports/brechas_corpus.json` y `corpus_manifest.json`.

Versión del inventario: 53a7b5214f1f492da49b7a8737a073a941129a3e4d692c9481e727bc77734bcd